





人工智能驱动科学研究导论 课程笔记

2026 春

冯翊展





目录

前言	3
----------	---

I

Part I 人工智能基础

1 绪论	5
2 概率统计基础	9
3 回归与分类	14

II

Part II 时间数据中的 AI 模型

III

Part III 空间数据中的 AI 模型

IV

Part IV 生成式模型

V

Part V 大语言模型

前言

本笔记是根据 2026 年春季周沛劼(pjzhou@pku.edu.cn)和韩铭(hanmingcr@pku.edu.cn)老师开设的“人工智能驱动科学研究导论”课程所整理。课程主要参考的教材为 *Deep Learning: Foundations and Concepts*，同时还可以参考 *Dive into Deep Learning* 和 *Understanding Deep Learning*。笔记主要根据课堂教授内容整理（每一章对应一节课），另外助教也提供了针对教材内容的讲义（参见附录）。

Part I 人工智能基础

1	绪论	5
1.1	机器学习：我们在学什么	5
1.2	如何衡量“接近”：K-L 散度	5
1.3	K-L 散度的非负性	6
1.4	学习目标：MLE	7
2	概率统计基础	9
2.1	基本框架	9
2.2	随机变量与分布	9
2.3	分布函数与密度函数	10
2.4	随机变量的数字特征：期望与方差	10
2.5	两个随机变量的关系	11
2.6	大数定律与中心极限定理	12
2.7	最大似然估计（MLE）	12
3	回归与分类	14
3.1	监督学习的基本框架	14
3.2	回归问题与最小二乘	14
3.3	线性基函数回归模型	15
3.4	正规方程与几何解释	15
3.5	MAP 与正则化	17
3.6	分类问题与 Logistic 回归	18

1. 绪论

1.1 机器学习：我们在学什么

设有一组样本

$$x_1, x_2, \dots, x_N, \quad x_i \in \mathbb{R}^d.$$

也就是说，每个样本 x_i 都是一个 d 维向量。这些样本可以看作是从某个真实但未知的数据分布中抽取出来的，这个分布记作 $P_{\text{data}}(x)$ 。

在机器学习中，我们通常希望构造一个带参数的模型分布 $P_{\theta}(x)$ ，其中 θ 表示模型参数。学习的目标就是调节参数 θ ，使得模型分布尽可能接近真实数据分布，即

$$P_{\theta}(x) \approx P_{\text{data}}(x).$$

一个典型例子是高斯分布。若模型假设数据服从某个高斯分布，则其密度可写成

$$p_{\theta}(x) \propto \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right),$$

参数为 $\theta = (\mu, \sigma)$ ，而学习就是通过数据去确定合适的 μ, σ ，使这个高斯分布尽量接近真实数据的分布。

1.2 如何衡量“接近”：K-L 散度

要让

$$P_{\theta}(x) \approx P_{\text{data}}(x),$$

首先需要有一个“距离”或“差异”的度量。这里引入一个非常重要的量：**K-L 散度**。

对于两个概率分布 P 和 Q ，其 K-L 散度定义为

$$D_{\text{KL}}(P\|Q) \equiv \int p(x) \log \frac{p(x)}{q(x)} dx.$$

这里 $p(x), q(x)$ 分别是分布 P, Q 的密度。它衡量的是：如果真实分布是 P ，但我们用 Q 来近似，会有多大的信息损失。

把 K-L 散度展开：

$$D_{\text{KL}}(P\|Q) = \int p(x) \log p(x) dx - \int p(x) \log q(x) dx.$$

注意到

$$-\int p(x) \log p(x) \, dx,$$

这正是分布 P 的熵:

$$H(P) = -\int p(x) \log p(x) \, dx.$$

通常定义交叉熵为

$$H(P, Q) \equiv -\int p(x) \log q(x) \, dx,$$

于是有

$$D_{\text{KL}}(P\|Q) = H(P, Q) - H(P).$$

这说明:

- $H(P)$ 是真实分布本身的不确定性;
- $H(P, Q)$ 是用 Q 来描述 P 时的平均代价;
- 二者之差就是额外损失, 也就是 **K-L 散度**。

1.3 K-L 散度的非负性

K-L 散度最重要的性质之一是

$$D_{\text{KL}}(P\|Q) \geq 0.$$

并且只有当 $P = Q$ 才有 $D_{\text{KL}}(P\|Q) = 0$ 。这说明 **K-L 散度** 虽然不一定是严格意义上的“距离”, 但至少满足非负且相同则为零这一重要性质, 因此非常适合作为分布拟合的目标函数。

下面来推导这一性质。从定义出发,

$$D_{\text{KL}}(P\|Q) = \int p(x) \log \frac{p(x)}{q(x)} \, dx.$$

把它改写成

$$D_{\text{KL}}(P\|Q) = -\int p(x) \log \frac{q(x)}{p(x)} \, dx.$$

现在考虑函数

$$f(t) = -\log t.$$

这个函数是一个凸函数, 因此可以使用 **Jensen 不等式**:

$$\int p(x) f\left(\frac{q(x)}{p(x)}\right) \, dx \geq f\left(\int p(x) \frac{q(x)}{p(x)} \, dx\right).$$

代入 $f(t) = -\log t$, 得到

$$-\int p(x) \log \frac{q(x)}{p(x)} \, dx \geq -\log \left(\int p(x) \frac{q(x)}{p(x)} \, dx \right).$$

而右边括号内可化简为

$$\int p(x) \frac{q(x)}{p(x)} \, dx = \int q(x) \, dx = 1.$$

所以

$$D_{\text{KL}}(P\|Q) \geq -\log 1 = 0.$$

因此得到

$$D_{\text{KL}}(P\|Q) \geq 0.$$

1.4 学习目标：MLE

在概率建模中，我们希望用参数化模型分布 $P_\theta(x)$ 去逼近真实的数据分布 $P_{\text{data}}(x)$ ，即选择参数 θ ，使得模型分布与真实分布之间的 K-L 散度最小：

$$\min_{\theta} D_{\text{KL}}(P_{\text{data}} \| P_{\theta}).$$

这里

$$D_{\text{KL}}(P_{\text{data}} \| P_{\theta}) = \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_{\theta}(x)} dx.$$

展开 K-L 散度

$$D_{\text{KL}}(P_{\text{data}} \| P_{\theta}) = \int p_{\text{data}}(x) \log p_{\text{data}}(x) dx - \int p_{\text{data}}(x) \log p_{\theta}(x) dx.$$

注意到第一项

$$\int p_{\text{data}}(x) \log p_{\text{data}}(x) dx$$

只和真实分布 P_{data} 有关，与参数 θ 无关。因此，在对 θ 做优化时，这一项可以视为常数。于是最小化 K-L 散度就等价于最小化

$$- \int p_{\text{data}}(x) \log p_{\theta}(x) dx,$$

也等价于最大化

$$\int p_{\text{data}}(x) \log p_{\theta}(x) dx.$$

所以有

$$\min_{\theta} D_{\text{KL}}(P_{\text{data}} \| P_{\theta}) \iff \max_{\theta} \int p_{\text{data}}(x) \log p_{\theta}(x) dx.$$

进一步，上式中的

$$\int p_{\text{data}}(x) \log p_{\theta}(x) dx$$

其实就是在真实数据分布下， $\log p_{\theta}(x)$ 的期望：

$$\mathbb{E}_{x \sim P_{\text{data}}} [\log p_{\theta}(x)].$$

但在实际问题中，我们并不知道真实分布 P_{data} 的具体表达式，只知道一组样本

$$x_1, x_2, \dots, x_N.$$

于是就用样本平均来近似这个期望：

$$\mathbb{E}_{x \sim P_{\text{data}}} [\log p_{\theta}(x)] \approx \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i).$$

因此，优化目标就变成

$$\max_{\theta} \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i).$$

因为对数函数是单调递增的，最大化

$$\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i)$$

等价于最大化

$$\prod_{i=1}^N p_{\theta}(x_i).$$

后者正是样本的似然函数：

$$L(\theta) = \prod_{i=1}^N p_{\theta}(x_i).$$

因此，最优参数可以写成

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \prod_{i=1}^N p_{\theta}(x_i),$$

或者等价地写成

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \sum_{i=1}^N \log p_{\theta}(x_i).$$

这说明最小化

$$D_{\text{KL}}(P_{\text{data}} \| P_{\theta})$$

的结果，就是最大似然估计（MLE）。

2. 概率统计基础

2.1 基本框架

概率论的基本框架由三元组

$$(\Omega, \mathcal{F}, P)$$

给出，其中：

- Ω 为**样本空间**，表示所有可能结果的集合；
- $\mathcal{F}$ 为**事件集合**，其中每个事件 $A \in \mathcal{F}$ 满足 $A \subseteq \Omega$ ；
- P 为**概率测度**，对任意事件 $A \in \mathcal{F}$ ，有

$$0 \leq P(A) \leq 1, \quad P(\Omega) = 1, \quad P(\emptyset) = 0.$$

2.2 随机变量与分布

随机变量 X 是定义在样本空间上的函数：

$$X(\omega) \in \mathbb{R}.$$

也就是说，随机变量把随机试验的结果 ω 映射为一个实数。

若 $B \subseteq \mathbb{R}$ 是实数上的一个集合，则事件 “ $X \in B$ ” 定义为

$$\{\omega \mid X(\omega) \in B\}.$$

因此随机变量 X 在实数轴上诱导出一个概率分布：

$$P(X \in B) \equiv P(\{\omega \mid X(\omega) \in B\}).$$

这说明：随机变量本身是一个函数，而分布描述的是这个函数取不同值时的概率规律。

随机变量通常分为两类：

- **离散型随机变量**：取值是有限个或可数个；
- **连续型随机变量**：取值落在某个连续区间上。

2.2.1 Bernoulli 分布

最简单的离散分布之一是 Bernoulli 分布。若

$$P(X = 1) = p, \quad P(X = 0) = 1 - p,$$

则称 $X \sim \text{Bernoulli}(p)$ 。

这类随机变量常用来描述“是否发生某件事”。

2.2.2 正态分布

典型的连续型分布是正态分布 (Gauss 分布)。若

$$X \sim \mathcal{N}(\mu, \sigma^2),$$

则其概率密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

其中:

- μ 是均值;
 - σ^2 是方差;
 - σ 是标准差。
- 并且满足归一化条件

$$\int_{-\infty}^{+\infty} p(x) \mathrm{d}x = 1.$$

2.3 分布函数与密度函数

对任意随机变量 X , 其累积分布函数 (CDF) 定义为

$$F(x) = P(X \leq x).$$

若 X 是连续型随机变量, 存在函数 $p(x)$ 使得

$$F(x) = \int_{-\infty}^x p(z) \mathrm{d}z,$$

则称 $p(x)$ 为 X 的概率密度函数 (PDF)。此时任意区间概率可写成

$$P(a < X \leq b) = \int_a^b p(z) \mathrm{d}z = F(b) - F(a).$$

若 F 可导, 则

$$p(x) = F'(x).$$

2.4 随机变量的数字特征: 期望与方差

2.4.1 离散型情形

设离散型随机变量 X 取值为 k , 概率为 $P_k = P(X = k)$ 。则其期望为

$$E(X) = \sum_k k P_k.$$

对任意函数 $f(X)$, 有

$$E(f(X)) = \sum_k f(k) P_k.$$

2.4.2 连续型情形

若 X 的密度函数为 $p(x)$, 则

$$E(X) = \int_{-\infty}^{+\infty} x p(x) \mathrm{d}x,$$

更一般地,

$$E(f(X)) = \int_{-\infty}^{+\infty} f(x) p(x) \mathrm{d}x.$$

2.4.3 方差

方差刻画随机变量围绕均值的波动程度, 定义为

$$\text{Var}(X) = E((X - E(X))^2).$$

也可写为

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

对于连续型随机变量,

$$\text{Var}(X) = \int_{-\infty}^{+\infty} x^2 p(x) dx - \left(\int_{-\infty}^{+\infty} x p(x) dx \right)^2.$$

2.4.4 线性变换下的均值与方差

若

$$Y = kX + b,$$

则

$$E(Y) = kE(X) + b, \quad \text{Var}(Y) = k^2 \text{Var}(X).$$

2.5 两个随机变量的关系

设有两个随机变量 X, Y 。

2.5.1 联合分布

若 X, Y 都是离散型, 则联合分布可记为

$$P(x, y) = P(X = x, Y = y).$$

若是连续型, 则写作联合密度 $p(x, y)$ 。

2.5.2 边缘分布

由联合分布可得到边缘分布。连续情形下:

$$p(x) = \int_{-\infty}^{+\infty} p(x, y) dy, \quad p(y) = \int_{-\infty}^{+\infty} p(x, y) dx.$$

2.5.3 条件分布

条件分布定义为

$$p(x | y) = \frac{p(x, y)}{p(y)}, \quad p(y | x) = \frac{p(x, y)}{p(x)}.$$

等价地,

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x).$$

由此可以推出 Bayes 公式,

$$p(x | y) = \frac{p(y | x)p(x)}{p(y)}.$$

2.5.4 独立性

若 X 与 Y 独立, 则

$$p(x, y) = p(x)p(y).$$

这等价于

$$p(x | y) = p(x), \quad p(y | x) = p(y).$$

2.6 大数定律与中心极限定理

2.6.1 大数定律

设

$$X_1, X_2, \dots, X_n$$

是独立同分布 (i.i.d.) 随机变量 (每个变量的概率分布都相同, 且这些随机变量互相独立), 且

$$E(X) = \mu.$$

记样本均值为

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

大数定律说明: 当 $n \rightarrow \infty$ 时, 样本均值会趋近于总体均值 μ :

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| > \varepsilon\right) = 0.$$

更一般的, 对于函数 $f(X)$,

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \rightarrow E(f(X)),$$

其中

$$E(f(X)) = \int f(x)p(x) \mathrm{d}x.$$

这给出了 Monte Carlo 方法的理论基础: **用样本平均逼近期望**。

2.6.2 中心极限定理

在同样的 i.i.d. 条件下, 若 X 方差有限, 则样本均值在大样本下近似服从正态分布:

$$\frac{1}{n} \sum_{k=1}^n X_k \approx \mathcal{N}\left(\mu, \frac{\mathrm{Var}(X)}{n}\right).$$

这说明:

- 样本均值的波动会随着 n 增大而减小;
- 其方差缩小为 $\mathrm{Var}(X)/n$;
- 大样本下可以用 Gauss 分布近似描述样本均值的不确定性。

2.7 最大似然估计 (MLE)

绪论中我们推导了学习的目标——最小化 K-L 散度——本质上是一个最大似然估计 (MLE)。现在我们来推导两种分布参数的 MLE。

2.7.1 Gauss 分布参数的 MLE

设

$$x_1, x_2, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2).$$

则

$$p_{\theta}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad \theta = (\mu, \sigma).$$

其对数似然函数为

$$\sum_{i=1}^n \log p_{\theta}(x_i) = \sum_{i=1}^n \left[-\frac{(x_i - \mu)^2}{2\sigma^2} - \log(\sqrt{2\pi}\sigma) \right].$$

因此最大化对数似然等价于最小化损失函数

$$L(\mu, \sigma) = \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 + n \log(\sqrt{2\pi}\sigma).$$

对 μ 求偏导并令其为 0, 得

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i.$$

对 σ 求偏导并令其为 0, 得

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

因此, Gauss 分布的 MLE 给出:

- 均值的估计是样本均值;
- 方差的估计是以 n 为分母的样本平方偏差平均。

2.7.2 Bernoulli 分布参数的 MLE

我们可以把 Bernoulli 分布写作

$$x_n \in \{0, 1\}, \quad p(x | \mu) = \mu^x (1 - \mu)^{1-x},$$

其中 μ 表示取值为 1 的概率。于是对数似然为

$$L(\mu) = \sum_{n=1}^N \ln p(x_n | \mu) = \sum_{n=1}^N [x_n \ln \mu + (1 - x_n) \ln(1 - \mu)].$$

对 μ 求导并令其为零:

$$\frac{dL}{d\mu} = \sum_{n=1}^N \frac{x_n}{\mu} - \sum_{n=1}^N \frac{1 - x_n}{1 - \mu} = 0.$$

记

$$S_N = \sum_{n=1}^N x_n,$$

则上式化为

$$\frac{S_N}{\mu} = \frac{N - S_N}{1 - \mu}.$$

解得

$$\hat{\mu} = \frac{S_N}{N} = \frac{1}{N} \sum_{n=1}^N x_n.$$

因此, Bernoulli 分布参数的最大似然估计就是样本均值。

3. 回归与分类

3.1 监督学习的基本框架

监督学习 (Supervised Learning) 通常分为两类:

- 回归 (regression): 输出为连续值;
- 分类 (classification): 输出为离散类别。

很多机器学习问题都可以表述为: 先建立一个参数化模型, 再通过优化某个目标函数来学习参数。

3.2 回归问题与最小二乘

设第 n 个样本输入为 x_n , 目标输出为 t_n , 建立模型

$$t_n = y(x_n, w) + \varepsilon_n,$$

其中 w 是模型参数, ε_n 是噪声项。

若假设噪声独立同分布且服从高斯分布

$$\varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

则

$$p(t_n | x_n, w) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(t_n - y(x_n, w))^2}{2\sigma^2}\right).$$

于是最大化对数似然

$$\max_w \sum_{n=1}^N \ln p(t_n | x_n, w)$$

等价于最小化

$$\min_w \sum_{n=1}^N (t_n - y(x_n, w))^2.$$

如果再除以 N , 就得到均方误差 (MSE):

$$\text{MSE} = \frac{1}{N} \sum_{n=1}^N (t_n - y(x_n, w))^2.$$

所以, 在高斯噪声假设下, 最大似然估计等价于最小二乘。

3.3 线性基函数回归模型

3.3.1 模型形式

线性基函数模型 (linear basis function model) 的形式是

$$y(x, w) = w^\top \phi(x),$$

其中

$$w \in \mathbb{R}^M, \quad x \in \mathbb{R}^d, \quad y \in \mathbb{R}.$$

这里的 $\phi(x)$ 是基函数向量:

$$\phi(x) = \begin{pmatrix} \phi_1(x) \\ \phi_2(x) \\ \vdots \\ \phi_M(x) \end{pmatrix}.$$

因此

$$y(x, w) = w_1 \phi_1(x) + w_2 \phi_2(x) + \cdots + w_M \phi_M(x).$$

注意: 这类模型对参数 w 是线性的, 但对输入 x 不一定线性, 因为 $\phi(x)$ 可以是任意非线性变换。

3.3.2 几种常见基函数举例

例 1: 直接使用输入分量 若 $x \in \mathbb{R}^M$, 取

$$\phi_k(x) = x_k,$$

则

$$w^\top \phi(x) = w^\top x = w_1 x_1 + w_2 x_2 + \cdots + w_M x_M.$$

例 2: 多项式基函数 若 $x \in \mathbb{R}$, 可取

$$\phi(x) = \begin{pmatrix} 1 \\ x \\ x^2 \\ \vdots \\ x^{M-1} \end{pmatrix},$$

则

$$w^\top \phi(x) = w_0 + w_1 x + \cdots + w_{M-1} x^{M-1}.$$

例 3: 三角基函数 例如可取

$$\phi_k(x) = \sin(kx), \quad \phi_k(x) = \cos(kx),$$

用于表示周期性结构。

3.4 正规方程与几何解释

3.4.1 最小二乘的矩阵形式

对所有样本, 记目标向量为

$$T = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix} \in \mathbb{R}^N,$$

设计矩阵 (design matrix) 为

$$\Phi = \begin{pmatrix} \phi(x_1)^\top \\ \phi(x_2)^\top \\ \vdots \\ \phi(x_N)^\top \end{pmatrix} = \begin{pmatrix} \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_M(x_1) \\ \phi_1(x_2) & \phi_2(x_2) & \cdots & \phi_M(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_N) & \phi_2(x_N) & \cdots & \phi_M(x_N) \end{pmatrix} \in \mathbb{R}^{N \times M}.$$

参数向量为

$$w = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_M \end{pmatrix}.$$

于是回归模型可写成

$$T = \Phi w + \varepsilon,$$

其中

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{pmatrix}.$$

最小二乘目标函数写成

$$E(w) = \frac{1}{2} \sum_{n=1}^N (t_n - w^\top \phi(x_n))^2 = \frac{1}{2} \|T - \Phi w\|^2.$$

3.4.2 正规方程

为了求最优参数, 对 $E(w)$ 求导:

$$E(w) = \frac{1}{2} (T - \Phi w)^\top (T - \Phi w).$$

展开可得

$$E(w) = \frac{1}{2} (T^\top T - 2T^\top \Phi w + w^\top \Phi^\top \Phi w).$$

对 w 求梯度并令其为零:

$$\frac{\partial E(w)}{\partial w} = -\Phi^\top T + \Phi^\top \Phi w = 0.$$

因此得到正规方程 (normal equation):

$$\Phi^\top \Phi w = \Phi^\top T.$$

若 $\Phi^\top \Phi$ 可逆, 则

$$w^* = (\Phi^\top \Phi)^{-1} \Phi^\top T.$$

3.4.3 几何解释

最小二乘的几何意义是: 由于噪声的存在, T 并不在由 Φ 的列向量张成的子空间中, 因此我们需要寻找最接近目标向量 T 的点 Φw^* , 也就是说, 误差向量

$$\varepsilon = T - \Phi w^*$$

与该子空间正交, 因此

$$\Phi^\top (T - \Phi w^*) = 0.$$

这正是正规方程的几何形式。

3.5 MAP 与正则化

现在我们回过头来思考，参数 w 是如何选取的。在线性回归或分类模型中，经典统计通常将 w 视为一个固定但未知的参数，随机性来自观测数据中的噪声。因此，我们通过观测样本 (x_n, t_n) ，并最大化似然函数 $p(D | w)$ 或最小化相应损失函数，来求得一个最优估计 $\hat{w}$ 。

然而，贝叶斯概率论提供了另一种理解方式：由于我们在观测数据之前并不知道参数 w 的真实取值，因此也可以将 w 本身看作随机变量，并用先验分布 $p(w)$ 描述我们对其取值的先验信念。结合观测数据后，便可通过贝叶斯公式得到参数的后验分布

$$p(w | D) = \frac{p(D | w)p(w)}{p(D)}.$$

贝叶斯方法并不是简单地寻找单个最优参数，而是通过数据不断更新我们对参数 w 的概率认识。

因此除了 MLE 之外，我们还可以引入参数先验，使用最大后验估计 (MAP, Maximum A Posteriori)。根据上述公式，因为 $p(D)$ 与 w 无关，所以

$$\max_w \ln p(w | D) = \max_w [\ln p(D | w) + \ln p(w)].$$

3.5.1 高斯先验与 L_2 正则

若对参数取高斯先验

$$p(w) = \frac{1}{(2\pi)^{M/2}\sigma_w^M} \exp\left(-\frac{\|w\|^2}{2\sigma_w^2}\right),$$

则

$$\ln p(w) = -\frac{1}{2\sigma_w^2} \|w\|^2 + \text{const.}$$

因此最大化后验概率等价于最小化

$$\sum_{n=1}^N (t_n - w^\top \phi(x_n))^2 + \lambda \|w\|^2,$$

其中 $\lambda > 0$ 为正则化系数。

这就是 L_2 正则化，也称 Ridge 回归。其解析解为

$$w^* = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top T.$$

3.5.2 L_1 正则

若改用

$$\lambda \sum_{i=1}^M |w_i|,$$

则得到 L_1 正则化，也即 Lasso。它倾向于产生稀疏解，即使部分参数精确变成零。

因此，正则化最小化问题可以统一写成

$$\min_w \sum_{n=1}^N (t_n - w^\top \phi(x_n))^2 + \lambda \Omega(w),$$

其中

$$\Omega(w) = \|w\|^2 \quad \text{或} \quad \Omega(w) = \sum_{i=1}^M |w_i|.$$

3.6 分类问题与 Logistic 回归

3.6.1 二分类的概率建模

对于二分类问题，令

$$t_n \in \{0, 1\},$$

并定义打分函数

$$a_n = w^\top \phi(x_n).$$

使用 sigmoid 函数

$$\sigma(a) = \frac{1}{1 + \exp(-a)}$$

压缩到 $(0, 1)$ 。于是可建模为

$$p(t_n = 1 \mid x_n) = \sigma(a_n), \quad p(t_n = 0 \mid x_n) = 1 - \sigma(a_n).$$

因此单个样本的条件概率可以统一写为

$$p(t_n \mid x_n) = \sigma(a_n)^{t_n} (1 - \sigma(a_n))^{1-t_n}.$$

3.6.2 对数似然与交叉熵

对于整个数据集，最大化对数似然等价于最大化

$$\sum_{n=1}^N \left[t_n \ln \sigma(a_n) + (1 - t_n) \ln(1 - \sigma(a_n)) \right].$$

等价地，也可最小化负对数似然

$$E(w) = - \sum_{n=1}^N \left[t_n \ln \sigma(a_n) + (1 - t_n) \ln(1 - \sigma(a_n)) \right].$$

这就是二分类中的交叉熵损失（cross-entropy loss）。

与线性回归不同，这里通常没有简单的闭式解，因此需要迭代优化。

3.6.3 梯度下降法

为求解

$$\min_w E(w),$$

其中

$$E(w) = \sum_{n=1}^N E_n(w),$$

常见的数值优化方法是梯度下降（Gradient Descent, GD）：

$$w_{k+1} = w_k - \eta \nabla_w E(w_k),$$

其中 η 为学习率（learning rate）。

其思想是：在当前位置计算目标函数的梯度，沿负梯度方向更新参数，从而逐步减小误差函数。

3.6.4 从生成式观点理解 Logistic 形式

最后我们给出了一个从生成模型推导二分类后验概率为 sigmoid 形式的思路。设两类分别为 C_1, C_2 ，由贝叶斯公式有

$$p(C_1 | x) = \frac{p(x | C_1)p(C_1)}{p(x | C_1)p(C_1) + p(x | C_2)p(C_2)}.$$

令

$$a = \ln \frac{p(x | C_1)p(C_1)}{p(x | C_2)p(C_2)},$$

则可写成

$$p(C_1 | x) = \frac{1}{1 + \exp(-a)} = \sigma(a).$$

若进一步假设类条件分布为高斯分布

$$p(x | C_k) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^\top \Sigma^{-1}(x - \mu_k)\right), \quad x \in \mathbb{R}^d,$$


并且两类共享同一个协方差矩阵 $\Sigma_{d \times d}$ ，则可以推出

$$a(x) = w^\top x + w_0,$$

从而

$$p(C_1 | x) = \sigma(w^\top x + w_0).$$

这说明：在线性高斯生成模型的假设下，后验概率会自然具有 Logistic 回归的形式。



Part II 时间数据中的 AI 模型

Part III 空间数据中的 AI 模型

IV

Part IV 生成式模型

