

人工智能驱动科学研究导论（2026 年春）

Introduction of AI for Science, Spring 2026

冯翊展

2400017802@stu.pku.edu.cn

2026 年 3 月 31 日

目录

1 绪论	2
1.1 机器学习：我们在学什么	2
1.2 如何衡量“接近”：K-L 散度	2
1.3 K-L 散度的非负性	3
1.4 学习目标：MLE	3
2 前置知识：概率统计基础	5
2.1 基本框架	5
2.2 随机变量与分布	5
2.3 分布函数与密度函数	6
2.4 随机变量的数字特征：期望与方差	6
2.5 两个随机变量的关系	7
2.6 大数定律与中心极限定理	8
2.7 Gauss 分布参数的最大似然估计	9
2.8 线性回归与 MSE	9

1 绪论

1.1 机器学习：我们在学什么

设有一组样本

$$x_1, x_2, \dots, x_N, \quad x_i \in \mathbb{R}^d.$$

也就是说，每个样本 x_i 都是一个 d 维向量。这些样本可以看作是从某个真实但未知的数据分布中抽取出来的，这个分布记作 $P_{\text{data}}(x)$ 。

在机器学习中，我们通常希望构造一个带参数的模型分布 $P_{\theta}(x)$ ，其中 θ 表示模型参数。学习的目标就是调节参数 θ ，使得模型分布尽可能接近真实数据分布，即

$$P_{\theta}(x) \approx P_{\text{data}}(x).$$

一个典型例子是高斯分布。若模型假设数据服从某个高斯分布，则其密度可写成

$$p_{\theta}(x) \propto \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right),$$

参数为 $\theta = (\mu, \sigma)$ ，而学习就是通过数据去确定合适的 μ, σ ，使这个高斯分布尽量接近真实数据的分布。

1.2 如何衡量“接近”：K-L 散度

要让

$$P_{\theta}(x) \approx P_{\text{data}}(x),$$

首先需要有一个“距离”或“差异”的度量。这里引入一个非常重要的量：**K-L 散度**。

对于两个概率分布 P 和 Q ，其 K-L 散度定义为

$$D_{\text{KL}}(P\|Q) \equiv \int p(x) \log \frac{p(x)}{q(x)} dx.$$

这里 $p(x), q(x)$ 分别是分布 P, Q 的密度。它衡量的是：如果真实分布是 P ，但我们用 Q 来近似，会有多大的信息损失。

把 K-L 散度展开：

$$D_{\text{KL}}(P\|Q) = \int p(x) \log p(x) dx - \int p(x) \log q(x) dx.$$

注意到

$$- \int p(x) \log p(x) dx,$$

这正是分布 P 的熵：

$$H(P) = - \int p(x) \log p(x) dx.$$

通常定义交叉熵为

$$H(P, Q) \equiv - \int p(x) \log q(x) dx,$$

于是有

$$D_{\text{KL}}(P\|Q) = H(P, Q) - H(P).$$

这说明：

- $H(P)$ 是真实分布本身的不确定性；
- $H(P, Q)$ 是用 Q 来描述 P 时的平均代价；
- 二者之差就是额外损失，也就是 K-L 散度。

1.3 K-L 散度的非负性

K-L 散度最重要的性质之一是

$$D_{\text{KL}}(P\|Q) \geq 0.$$

并且只有当 $P = Q$ 才有 $D_{\text{KL}}(P\|Q) = 0$ 。这说明 K-L 散度虽然不一定是严格意义上的“距离”，但至少满足非负且相同则为零这一重要性质，因此非常适合作为分布拟合的目标函数。

下面来推导这一性质。从定义出发，

$$D_{\text{KL}}(P\|Q) = \int p(x) \log \frac{p(x)}{q(x)} dx.$$

把它改写成

$$D_{\text{KL}}(P\|Q) = - \int p(x) \log \frac{q(x)}{p(x)} dx.$$

现在考虑函数

$$f(t) = -\log t.$$

这个函数是一个凸函数，因此可以使用 Jensen 不等式：

$$\int p(x) f\left(\frac{q(x)}{p(x)}\right) dx \geq f\left(\int p(x) \frac{q(x)}{p(x)} dx\right).$$

代入 $f(t) = -\log t$ ，得到

$$- \int p(x) \log \frac{q(x)}{p(x)} dx \geq -\log \left(\int p(x) \frac{q(x)}{p(x)} dx \right).$$

而右边括号内可化简为

$$\int p(x) \frac{q(x)}{p(x)} dx = \int q(x) dx = 1.$$

所以

$$D_{\text{KL}}(P\|Q) \geq -\log 1 = 0.$$

因此得到

$$D_{\text{KL}}(P\|Q) \geq 0.$$

1.4 学习目标：MLE

在概率建模中，我们希望用参数化模型分布 $P_\theta(x)$ 去逼近真实的数据分布 $P_{\text{data}}(x)$ ，即选择参数 θ ，使得模型分布与真实分布之间的 K-L 散度最小：

$$\min_{\theta} D_{\text{KL}}(P_{\text{data}}\|P_\theta).$$

这里

$$D_{\text{KL}}(P_{\text{data}}\|P_\theta) = \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\theta(x)} dx.$$

展开 K-L 散度

$$D_{\text{KL}}(P_{\text{data}}\|P_\theta) = \int p_{\text{data}}(x) \log p_{\text{data}}(x) dx - \int p_{\text{data}}(x) \log p_\theta(x) dx.$$

注意到第一项

$$\int p_{\text{data}}(x) \log p_{\text{data}}(x) dx$$

只和真实分布 P_{data} 有关，与参数 θ 无关。因此，在对 θ 做优化时，这一项可以视为常数。于是最小化 K-L 散度就等价于最小化

$$- \int p_{\text{data}}(x) \log p_\theta(x) dx,$$

也等价于最大化

$$\int p_{\text{data}}(x) \log p_{\theta}(x) \, dx.$$

所以有

$$\min_{\theta} D_{\text{KL}}(P_{\text{data}} \| P_{\theta}) \iff \max_{\theta} \int p_{\text{data}}(x) \log p_{\theta}(x) \, dx.$$

进一步, 上式中的

$$\int p_{\text{data}}(x) \log p_{\theta}(x) \, dx$$

其实就是在真实数据分布下, $\log p_{\theta}(x)$ 的期望:

$$\mathbb{E}_{x \sim P_{\text{data}}} [\log p_{\theta}(x)].$$

但在实际问题中, 我们并不知道真实分布 P_{data} 的具体表达式, 只知道一组样本

$$x_1, x_2, \dots, x_N.$$

于是就用样本平均来近似这个期望:

$$\mathbb{E}_{x \sim P_{\text{data}}} [\log p_{\theta}(x)] \approx \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i).$$

因此, 优化目标就变成

$$\max_{\theta} \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i).$$

因为对数函数是单调递增的, 最大化

$$\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i)$$

等价于最大化

$$\prod_{i=1}^N p_{\theta}(x_i).$$

后者正是样本的似然函数:

$$L(\theta) = \prod_{i=1}^N p_{\theta}(x_i).$$

因此, 最优参数可以写成

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \prod_{i=1}^N p_{\theta}(x_i),$$

或者等价地写成

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \sum_{i=1}^N \log p_{\theta}(x_i).$$

这说明最小化

$$D_{\text{KL}}(P_{\text{data}} \| P_{\theta})$$

的结果, 就是最大似然估计 (MLE)。

2 前置知识：概率统计基础

2.1 基本框架

概率论的基本框架由三元组

$$(\Omega, \mathcal{F}, P)$$

给出，其中：

- Ω 为**样本空间**，表示所有可能结果的集合；
- $\mathcal{F}$ 为**事件集合**，其中每个事件 $A \in \mathcal{F}$ 满足 $A \subseteq \Omega$ ；
- P 为**概率测度**，对任意事件 $A \in \mathcal{F}$ ，有

$$0 \leq P(A) \leq 1, \quad P(\Omega) = 1, \quad P(\emptyset) = 0.$$

2.2 随机变量与分布

随机变量 X 是定义在样本空间上的函数：

$$X(\omega) \in \mathbb{R}.$$

也就是说，随机变量把随机试验的结果 ω 映射为一个实数。

若 $B \subseteq \mathbb{R}$ 是实数上的一个集合，则事件“ $X \in B$ ”定义为

$$\{\omega \mid X(\omega) \in B\}.$$

因此随机变量 X 在实数轴上诱导出一个概率分布：

$$P(X \in B) \equiv P(\{\omega \mid X(\omega) \in B\}).$$

这说明：随机变量本身是一个函数，而分布描述的是这个函数取不同值时的概率规律。

随机变量通常分为两类：

- **离散型随机变量**：取值是有限个或可数个；
- **连续型随机变量**：取值落在某个连续区间上。

2.2.1 Bernoulli 分布

最简单的离散分布之一是 Bernoulli 分布。若

$$P(X = 1) = p, \quad P(X = 0) = 1 - p,$$

则称 $X \sim \text{Bernoulli}(p)$ 。

这类随机变量常用来描述“是否发生某件事”。

2.2.2 正态分布

典型的连续型分布是正态分布（Gauss 分布）。若

$$X \sim \mathcal{N}(\mu, \sigma^2),$$

则其概率密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

其中：

- μ 是均值;
- σ^2 是方差;
- σ 是标准差。

并且满足归一化条件

$$\int_{-\infty}^{+\infty} p(x) dx = 1.$$

2.3 分布函数与密度函数

对任意随机变量 X , 其累积分布函数 (CDF) 定义为

$$F(x) = P(X \leq x).$$

若 X 是连续型随机变量, 存在函数 $p(x)$ 使得

$$F(x) = \int_{-\infty}^x p(z) dz,$$

则称 $p(x)$ 为 X 的概率密度函数 (PDF)。此时任意区间概率可写成

$$P(a < X \leq b) = \int_a^b p(z) dz = F(b) - F(a).$$

若 F 可导, 则

$$p(x) = F'(x).$$

2.4 随机变量的数字特征: 期望与方差

2.4.1 离散型情形

设离散型随机变量 X 取值为 k , 概率为 $P_k = P(X = k)$ 。则其期望为

$$E(X) = \sum_k k P_k.$$

对任意函数 $f(X)$, 有

$$E(f(X)) = \sum_k f(k) P_k.$$

2.4.2 连续型情形

若 X 的密度函数为 $p(x)$, 则

$$E(X) = \int_{-\infty}^{+\infty} x p(x) dx,$$

更一般地,

$$E(f(X)) = \int_{-\infty}^{+\infty} f(x) p(x) dx.$$

2.4.3 方差

方差刻画随机变量围绕均值的波动程度，定义为

$$\text{Var}(X) = E((X - E(X))^2).$$

也可写为

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

对于连续型随机变量，

$$\text{Var}(X) = \int_{-\infty}^{+\infty} x^2 p(x) dx - \left(\int_{-\infty}^{+\infty} x p(x) dx \right)^2.$$

2.4.4 线性变换下的均值与方差

若

$$Y = kX + b,$$

则

$$E(Y) = kE(X) + b, \quad \text{Var}(Y) = k^2 \text{Var}(X).$$

2.5 两个随机变量的关系

设有两个随机变量 X, Y 。

2.5.1 联合分布

若 X, Y 都是离散型，则联合分布可记为

$$P(x, y) = P(X = x, Y = y).$$

若是连续型，则写作联合密度 $p(x, y)$ 。

2.5.2 边缘分布

由联合分布可得到边缘分布。连续情形下：

$$p(x) = \int_{-\infty}^{+\infty} p(x, y) dy, \quad p(y) = \int_{-\infty}^{+\infty} p(x, y) dx.$$

2.5.3 条件分布

条件分布定义为

$$p(x | y) = \frac{p(x, y)}{p(y)}, \quad p(y | x) = \frac{p(x, y)}{p(x)}.$$

等价地，

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x).$$

由此可以推出 Bayes 公式，

$$p(x | y) = \frac{p(y | x)p(x)}{p(y)}.$$

2.5.4 独立性

若 X 与 Y 独立, 则

$$p(x, y) = p(x)p(y).$$

这等价于

$$p(x | y) = p(x), \quad p(y | x) = p(y).$$

2.6 大数定律与中心极限定理

2.6.1 大数定律

设

$$X_1, X_2, \dots, X_n$$

是独立同分布 (i.i.d.) 随机变量 (每个变量的概率分布都相同, 且这些随机变量互相独立), 且

$$E(X) = \mu.$$

记样本均值为

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

大数定律说明: 当 $n \rightarrow \infty$ 时, 样本均值会趋近于总体均值 μ :

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| > \varepsilon\right) = 0.$$

更一般的, 对于函数 $f(X)$,

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \rightarrow E(f(X)),$$

其中

$$E(f(X)) = \int f(x)p(x) dx.$$

这给出了 Monte Carlo 方法的理论基础: 用样本平均逼近期望。

2.6.2 中心极限定理

在同样的 i.i.d. 条件下, 若 X 方差有限, 则样本均值在大样本下近似服从正态分布:

$$\frac{1}{n} \sum_{k=1}^n X_k \approx \mathcal{N}\left(\mu, \frac{\text{Var}(X)}{n}\right).$$

这说明:

- 样本均值的波动会随着 n 增大而减小;
- 其方差缩小为 $\text{Var}(X)/n$;
- 大样本下可以用 Gauss 分布近似描述样本均值的不确定性。

2.7 Gauss 分布参数的最大似然估计

绪论中我们推导了学习的目标——最小化 K-L 散度——本质上是一个最大似然估计 (MLE)。现在我们来推导 Gauss 分布的 MLE。

设

$$x_1, x_2, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2).$$

则

$$p_{\theta}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad \theta = (\mu, \sigma).$$

其对数似然函数为

$$\sum_{i=1}^n \log p_{\theta}(x_i) = \sum_{i=1}^n \left[-\frac{(x_i - \mu)^2}{2\sigma^2} - \log(\sqrt{2\pi}\sigma) \right].$$

因此最大化对数似然等价于最小化损失函数

$$L(\mu, \sigma) = \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 + n \log(\sqrt{2\pi}\sigma).$$

对 μ 求偏导并令其为 0，得

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i.$$

对 σ 求偏导并令其为 0，得

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

因此，Gauss 分布的 MLE 给出：

- 均值的估计是样本均值；
- 方差的估计是以 n 为分母的样本平方偏差平均。

2.8 线性回归与 MSE

设输入为 x ，输出为 t ，模型写作

$$t = y(x, \mathbf{w}) + \varepsilon,$$

其中：

- $y(x, \mathbf{w})$ 是确定性部分，例如线性模型

$$y = w_1 x + w_0,$$

或更一般的多项式模型；

- $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 是噪声。

因此条件分布为

$$p(t | x, \mathbf{w}) \sim \mathcal{N}(y(x, \mathbf{w}), \sigma^2).$$

给定训练样本 $\{(x_i, t_i)\}_{i=1}^n$ ，最大化条件对数似然：

$$\max_{\mathbf{w}} \sum_{i=1}^n \log p(t_i | x_i, \mathbf{w}).$$

在 Gauss 噪声假设下，这等价于最小化

$$\frac{1}{n} \sum_{i=1}^n (t_i - y(x_i, \mathbf{w}))^2,$$

即最小化均方误差 (MSE)。

所以：Gauss 噪声假设 $\Rightarrow$ 最大似然估计等价于最小二乘回归。