

Chapter 2 Notes

Probabilities

AI for Science

2026 年 3 月 30 日

目录

1 导读：概率论在机器学习中的角色	2
2 概率规则：联合、边缘、条件	2
2.1 加法规则与乘法规则	2
2.2 Bayes 公式	3
3 连续变量：密度、分布函数与矩	4
3.1 概率密度函数	4
3.2 期望、方差与协方差	4
4 高斯分布与最大似然	5
4.1 一维高斯分布	5
4.2 样本均值与样本方差的最大似然	5
5 随机变量变换与 Jacobian	6
6 信息论量：熵、交叉熵、KL 与互信息	7
7 贝叶斯参数推断	8
8 总结与常见误区	8

1 导读：概率论在机器学习中的角色

本章建立后续全书都会反复使用的概率语言。主线是

规则概率 → 密度与矩 → 高斯与似然 → 变量变换 → 信息论 → 贝叶斯更新.

学习目标

- 理解联合分布、边缘分布、条件分布之间的关系。
- 掌握期望、方差、协方差以及高斯分布的基本计算。
- 会从定义推到 Bayes 公式、密度变换公式和 KL 散度。

2 概率规则：联合、边缘、条件

2.1 加法规则与乘法规则

联合分布的两种基本操作

$$p(x) = \sum_y p(x, y), \quad (1)$$

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x). \quad (2)$$

变量释义： $p(x, y)$ 是联合分布， $p(x)$ 是边缘分布， $p(x | y)$ 是条件分布。

推导思路 (2-4 步)：

1. 联合分布描述两个变量同时取值的概率。
2. 如果只关心 x ，就把所有可能的 y 加总掉，这就是边缘化。
3. 如果先知道 y ，再看 x 的概率，就得到条件分布，从而写出乘法规则。

何时使用： 推导概率模型结构、消去不关心的变量、分解复杂联合概率。

2.2 Bayes 公式

Bayes 更新

$$p(y | x) = \frac{p(x, y)}{p(x)} \quad (3)$$

$$= \frac{p(x | y)p(y)}{\sum_{y'} p(x | y')p(y')}. \quad (4)$$

变量释义： $p(y)$ 是先验 (prior)， $p(x | y)$ 是似然 (likelihood)， $p(y | x)$ 是后验 (posterior)。

推导思路 (2-4 步)：

1. 条件概率定义给出 $p(y | x) = p(x, y)/p(x)$ 。
2. 再用乘法规则把联合分布写成 $p(x | y)p(y)$ 。
3. 分母 $p(x)$ 是归一化常数，等于对所有可能 y 的总概率。

何时使用：分类、诊断、参数推断、本书后续的生成模型和变分推断。

为什么分母不能省略

分子 $p(x | y)p(y)$ 只告诉我们“类别 y 对观测 x 的解释力度”。但它还没有保证所有后验概率和为 1。

因此必须除以

$$p(x) = \sum_{y'} p(x | y')p(y'),$$

这一步就是把非归一化权重转成真正的概率分布。

3 连续变量：密度、分布函数与矩

3.1 概率密度函数

连续变量的概率由积分给出

$$P(a \leq X \leq b) = \int_a^b p(x) dx, \quad (5)$$

$$F(x) = P(X \leq x) = \int_{-\infty}^x p(t) dt. \quad (6)$$

变量释义： $p(x)$ 是概率密度函数（PDF）， $F(x)$ 是累积分布函数（CDF）。

推导思路（2-4 步）：

1. 连续情形下单点概率为 0，只能讨论区间概率。
2. 区间概率等于密度曲线在该区间下的面积。
3. 把下限固定到 $-\infty$ ，就得到累积分布函数。

何时使用：计算阈值概率、尾部风险、分位点和置信区间。

3.2 期望、方差与协方差

矩描述平均水平与波动

$$\mathbb{E}[f(X)] = \int f(x)p(x) dx, \quad (7)$$

$$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2, \quad (8)$$

$$\text{Cov}[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \quad (9)$$

变量释义：期望衡量平均水平，方差衡量波动程度，协方差衡量联动方向。

推导思路（2-4 步）：

1. 对随机变量的函数做加权平均，就得到期望。
2. 方差来自“偏离均值的平方”的期望。
3. 把平方展开，可得常用公式 $\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$ 。

何时使用：分析噪声规模、构造协方差矩阵、理解不确定性传播。

4 高斯分布与最大似然

4.1 一维高斯分布

高斯分布

$$\mathcal{N}(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right). \quad (10)$$

变量释义： μ 是均值， σ^2 是方差。

推导思路 (2-4 步)：

1. 指数项惩罚与均值的偏离，偏离越大概率越低。
2. 分母中的归一化常数保证积分为 1。
3. 方差越大，分布越平；方差越小，分布越尖。

何时使用： 观测噪声建模、回归误差建模、中心极限定理近似。

4.2 样本均值与样本方差的最大似然

高斯参数的 MLE

$$\log p(\mathbf{x} | \mu, \sigma^2) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2, \quad (11)$$

$$\hat{\mu} = \frac{1}{N} \sum_{n=1}^N x_n, \quad \hat{\sigma}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu})^2. \quad (12)$$

变量释义： $\mathbf{x} = (x_1, \dots, x_N)$ 是独立样本。

推导思路 (2-4 步)：

1. 先把独立样本的联合似然写成各项乘积，再取对数。
2. 对 μ 求导并令其为零，得到样本均值。
3. 对 σ^2 求导并令其为零，得到样本方差的 MLE。

何时使用： 参数估计、最小二乘解释、后续高斯生成模型。

为什么最小二乘对应高斯噪声

设回归模型为

$$t_n = y(x_n, \mathbf{w}) + \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \beta^{-1}).$$

则

$$p(\mathbf{t} | X, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | y(x_n, \mathbf{w}), \beta^{-1}), \quad (13)$$

$$-\log p(\mathbf{t} | X, \mathbf{w}, \beta) = \frac{\beta}{2} \sum_{n=1}^N (t_n - y(x_n, \mathbf{w}))^2 + C. \quad (14)$$

因此固定 β 时，最大化似然与最小化平方误差完全等价。

5 随机变量变换与 Jacobian

一维与多维变换公式

$$p_Z(z) = p_X(x) \left| \frac{dx}{dz} \right|, \quad z = g(x), \quad (15)$$

$$p_{\mathbf{z}}(\mathbf{z}) = p_{\mathbf{x}}(\mathbf{x}) \left| \det \frac{\partial \mathbf{x}}{\partial \mathbf{z}} \right|. \quad (16)$$

变量释义： Jacobian 行列式衡量局部体积伸缩。

推导思路 (2-4 步)：

1. 变换前后对应的小区间必须有相同概率质量。
2. 一维情形下，区间长度变化率就是 $|dx/dz|$ 。
3. 多维情形中，局部体积缩放由 Jacobian 行列式给出。

何时使用： 可逆生成模型、重参数化、流模型和采样变换。

一维变量变换的核心想法

若 $z = g(x)$ 单调可逆，则小区间满足

$$P(z \leq Z \leq z + \Delta z) = P(x \leq X \leq x + \Delta x).$$

两边分别近似为密度乘区间长度：

$$p_Z(z) \Delta z \approx p_X(x) \Delta x.$$

两边同除以 Δz 并令区间趋于 0，就得到

$$p_Z(z) = p_X(x) \left| \frac{dx}{dz} \right|.$$

6 信息论量：熵、交叉熵、KL 与互信息

三类核心量

$$H[p] = - \sum_x p(x) \log p(x), \quad (17)$$

$$H(p, q) = - \sum_x p(x) \log q(x), \quad (18)$$

$$\text{KL}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}, \quad (19)$$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}. \quad (20)$$

变量释义：熵衡量平均不确定性，交叉熵衡量“用 q 编码来自 p 的样本”的代价，KL 衡量分布不匹配，互信息衡量相关性。

推导思路 (2-4 步)：

1. KL 可写成交叉熵减熵： $\text{KL}(p||q) = H(p, q) - H(p)$ 。
2. 互信息本质上是联合分布与独立分布的 KL。
3. 因此互信息为零，当且仅当 X, Y 独立。

何时使用：分类训练目标、分布对齐、信息瓶颈、表示学习。

KL 非负性的两步证明思路

利用不等式 $\log a \leq a - 1$ ，令 $a = q(x)/p(x)$ ，可得

$$\log \frac{q(x)}{p(x)} \leq \frac{q(x)}{p(x)} - 1.$$

两边乘以 $-p(x)$ 并求和，得到

$$\sum_x p(x) \log \frac{p(x)}{q(x)} \geq \sum_x (p(x) - q(x)) = 0.$$

因此 $\text{KL}(p||q) \geq 0$ ，且等号仅在 $p = q$ 时成立。

7 贝叶斯参数推断

参数后验与预测分布

$$p(\mathbf{w} | \mathcal{D}) = \frac{p(\mathcal{D} | \mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}, \quad (21)$$

$$p(t_* | x_*, \mathcal{D}) = \int p(t_* | x_*, \mathbf{w}) p(\mathbf{w} | \mathcal{D}) d\mathbf{w}. \quad (22)$$

变量释义： $p(\mathbf{w})$ 是参数先验， $p(\mathbf{w} | \mathcal{D})$ 是参数后验，预测分布要对参数不确定性积分。

推导思路 (2-4 步)：

1. 先用数据把先验更新为后验。
2. 真正预测时，不是只用一个最佳参数，而是对所有可能参数加权平均。
3. 样本少时，这种做法通常比点估计更稳健。

何时使用：小样本学习、需要不确定性估计、模型比较与贝叶斯决策。

8 总结与常见误区

- 概率建模的基本操作只有三类：边缘化、条件化、变量变换。
- 高斯似然与最小二乘的联系，是很多监督学习方法的出发点。
- 交叉熵、KL 和互信息本质上都是“比较分布”的量，只是角度不同。
- 误区 1：把密度值当成概率值。
- 误区 2：只看似然，不看先验与归一化常数。
- 误区 3：把 KL 当作对称距离使用。