

Chapter 4 Notes  
Regression

AI for Science

2026 年 3 月 30 日

目录

|   |                      |   |
|---|----------------------|---|
| 1 | 导读：回归问题的主线           | 2 |
| 2 | 4.1 线性基函数模型          | 2 |
| 3 | 4.2 高斯似然与最小二乘        | 3 |
| 4 | 4.3 设计矩阵与正规方程        | 5 |
| 5 | 4.4 Ridge 回归与 MAP 解释 | 6 |
| 6 | 4.5 预测与偏差-方差权衡       | 6 |
| 7 | 总结与常见误区              | 7 |

# 1 导读：回归问题的主线

回归（Regression）研究的是如何从输入  $\mathbf{x}$  预测连续目标  $t$ 。这一章真正要掌握的不是“拟合一条曲线”，而是理解线性基函数模型、最大似然、正规方程和正则化之间是一条完整的概率建模链。主线是

线性基函数模型  $\rightarrow$  高斯似然与最小二乘  $\rightarrow$  正规方程  $\rightarrow$  Ridge / MAP  $\rightarrow$  预测与偏差-方差.

## 学习目标

- 理解“对参数线性”和“对输入非线性”如何同时成立。
- 掌握最小二乘、最大似然和正规方程之间的对应关系。
- 理解 ridge 正则化、MAP 解释以及偏差-方差权衡。

## 2 4.1 线性基函数模型

### 模型定义

$$y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j \phi_j(\mathbf{x}) = \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{x}). \quad (1)$$

变量释义：  $\phi_j(\mathbf{x})$  是第  $j$  个基函数，  $\boldsymbol{\phi}(\mathbf{x})$  是特征向量，  $\mathbf{w}$  是参数。

推导思路 (2-4 步)：

1. 先把原始输入映射到一组人工设计或学习得到的特征上。
2. 再对这些特征做线性加权，得到预测值。
3. 因此模型对参数仍是线性的，但对输入可以是高度非线性的。

何时使用：需要可解释性、可解析推导或希望把非线性关系写入特征映射时。

### 常见基函数

$$\phi_j(x) = x^j, \quad (2)$$

$$\phi_j(x) = \exp\left(-\frac{(x - \mu_j)^2}{2s^2}\right), \quad (3)$$

$$\phi_j(x) = \sigma\left(\frac{x - \mu_j}{s}\right). \quad (4)$$

变量释义：  $\mu_j$  是中心， $s$  控制尺度。

推导思路 (2-4 步)：

1. 多项式基函数适合表达全局平滑趋势。
2. Gaussian 基函数更像局部模板，适合表达局部变化。
3. Sigmoid 基函数则常用于分段过渡或类神经元激活近似。

何时使用： 根据任务的全局/局部结构选择合适特征展开方式。

## 3 4.2 高斯似然与最小二乘

### 平方损失

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2. \quad (5)$$

变量释义：  $(\mathbf{x}_n, t_n)$  是第  $n$  个训练样本。

推导思路 (2-4 步)：

1. 每个样本的误差是预测值减真实值。
2. 平方后可避免正负抵消，并更重地惩罚大误差。
3. 把所有样本误差求和，就得到经验风险。

何时使用： 连续目标且误差近似对称、单峰时。

## 高斯噪声似然

$$p(t_n | \mathbf{x}_n, \mathbf{w}, \beta) = \mathcal{N}(t_n | y(\mathbf{x}_n, \mathbf{w}), \beta^{-1}), \quad (6)$$

$$-\log p(\mathbf{t} | X, \mathbf{w}, \beta) = \frac{\beta}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2 + C. \quad (7)$$

**变量释义：**  $\beta$  是噪声精度，方差为  $\beta^{-1}$ 。

**推导思路 (2-4 步)：**

1. 假设目标值围绕模型输出做高斯波动。
2. 独立样本下，总似然是所有条件高斯的乘积。
3. 取负对数后，除了常数项外只剩平方误差和。

**何时使用：** 希望给最小二乘加上概率解释时。

## 为什么最小二乘不是拍脑袋设的

如果观测模型写成

$$t_n = y(\mathbf{x}_n, \mathbf{w}) + \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \beta^{-1}),$$

那么最大化似然就等价于最小化平方误差。

这说明“最小二乘”并不是一个脱离统计假设的纯数值目标，而是高斯观测噪声模型的直接结果。

## 预测分布

$$p(t | \mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t | \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{x}), \beta^{-1}). \quad (8)$$

**变量释义：** 在给定参数  $\mathbf{w}$  时，模型输出给出条件均值， $\beta^{-1}$  给出观测噪声方差。

**推导思路 (2-4 步)：**

1. 回归模型不只输出一个点预测，还隐含了条件分布假设。
2. 若噪声是高斯，则预测目标围绕均值做对称波动。
3. 这使回归模型能同时表达“预测值”和“不确定性尺度”。

**何时使用：** 从点估计走向概率回归、理解似然和预测误差的关系。

## 4 4.3 设计矩阵与正规方程

### 设计矩阵

$$\Phi = \begin{pmatrix} \phi(\mathbf{x}_1)^\top \\ \vdots \\ \phi(\mathbf{x}_N)^\top \end{pmatrix}, \quad \mathbf{y} = \Phi \mathbf{w}. \quad (9)$$

**变量释义：**  $\Phi$  的每一行是一个样本的特征向量。

**推导思路 (2-4 步)：**

1. 把逐样本写法统一改写成矩阵形式。
2. 这样损失、梯度和解析解都能更紧凑地表示。
3. 这也是后续推广到正则化、贝叶斯回归的标准入口。

**何时使用：** 进行解析推导、理解线性代数结构时。

### 正规方程

$$E_D(\mathbf{w}) = \frac{1}{2} \|\Phi \mathbf{w} - \mathbf{t}\|_2^2, \quad (10)$$

$$\nabla_{\mathbf{w}} E_D = \Phi^\top (\Phi \mathbf{w} - \mathbf{t}) = 0, \quad (11)$$

$$\mathbf{w}_{ML} = (\Phi^\top \Phi)^{-1} \Phi^\top \mathbf{t}. \quad (12)$$

**推导思路 (2-4 步)：**

1. 先把平方损失写成二次型。
2. 对  $\mathbf{w}$  求导并令梯度为零。
3. 若  $\Phi^\top \Phi$  可逆，就得到最大似然解析解。

**何时使用：** 中小规模线性回归、解析理解最优解结构时。

## 5 4.4 Ridge 回归与 MAP 解释

### Ridge 目标

$$E(\mathbf{w}) = \frac{1}{2} \|\Phi \mathbf{w} - \mathbf{t}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad (13)$$

$$\mathbf{w}_{ridge} = (\lambda I + \Phi^\top \Phi)^{-1} \Phi^\top \mathbf{t}. \quad (14)$$

变量释义： $\lambda$  控制参数惩罚强度。

推导思路 (2-4 步)：

1. 在数据项之外加上参数范数惩罚。
2. 对应梯度中多出  $\lambda \mathbf{w}$  一项。
3. 因而正规方程从  $\Phi^\top \Phi$  变成  $\lambda I + \Phi^\top \Phi$ ，数值稳定性更好。

何时使用：特征共线性强、参数多、训练数据有限时。

### Ridge 的 MAP 视角

若先验取

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \lambda^{-1} I),$$

则最大后验估计满足

$$\arg \max_{\mathbf{w}} p(\mathbf{t} \mid X, \mathbf{w}) p(\mathbf{w}).$$

对后验取负对数后，恰好得到“平方误差 +  $L_2$  惩罚”。

因此 ridge 不是凭经验硬加的项，而是“参数应接近零”的高斯先验的体现。

## 6 4.5 预测与偏差-方差权衡

### 偏差-方差分解

$$\mathbb{E}[(\hat{y}(\mathbf{x}) - t)^2] = \underbrace{(\mathbb{E}[\hat{y}(\mathbf{x})] - f^*(\mathbf{x}))^2}_{\text{bias}^2} + \underbrace{\mathbb{E}[(\hat{y}(\mathbf{x}) - \mathbb{E}[\hat{y}(\mathbf{x})])^2]}_{\text{variance}} + \sigma^2. \quad (15)$$

变量释义： $f^*(\mathbf{x})$  是真实回归函数， $\sigma^2$  是不可约噪声。

推导思路 (2-4 步)：

1. 在预测误差中加减平均预测值  $\mathbb{E}[\hat{y}(\mathbf{x})]$ 。
2. 展开平方后，交叉项因零均值而消失。
3. 从而把总误差拆成偏差平方、方差和噪声三部分。

何时使用：解释欠拟合、过拟合和模型复杂度选择。

## 7 总结与常见误区

- 线性回归的“线性”是对参数而言，并不代表只能拟合直线。
- 最小二乘、最大似然和高斯噪声模型是同一条逻辑链。
- Ridge 的本质是通过先验或惩罚限制模型有效复杂度。
- 误区 1：只看训练误差，不看验证误差和泛化表现。
- 误区 2：把解析解当作一定优于迭代法；高维问题往往并非如此。
- 误区 3：把正则化理解成“让参数变小”而忽略其统计含义。