

Chapter 5 Notes

Classification

AI for Science

2026 年 3 月 30 日

目录

1	导读：分类不只是画一条边界	2
2	5.1 判别函数与线性决策边界	2
3	5.2 Bayes classifier 与风险最小化	3
4	5.3 生成式与判别式	4
5	5.4 Logistic 回归	4
6	5.5 Softmax 回归	6
7	总结与常见误区	7

1 导读：分类不只是画一条边界

分类（Classification）研究的是如何把输入 $\mathbf{x}$ 映射到离散类别集合。要真正讲清这一章，必须把“判别函数”“后验概率”“决策规则”“损失函数”这些概念接成一条完整链条。主线是

判别函数 $\rightarrow$ Bayes classifier $\rightarrow$ 风险最小化 $\rightarrow$ 生成式与判别式 $\rightarrow$ Logistic / Softmax.

学习目标

- 掌握线性判别边界的几何含义。
- 理解最小错误率决策和代价敏感决策的区别。
- 掌握 logistic / softmax 模型的概率解释与交叉熵推导。

2 5.1 判别函数与线性决策边界

二分类线性判别函数

$$y(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0, \quad \hat{c} = \begin{cases} C_1, & y(\mathbf{x}) \geq 0, \\ C_2, & y(\mathbf{x}) < 0. \end{cases} \quad (1)$$

变量释义： $\mathbf{w}$ 是法向量， w_0 决定超平面偏移。

推导思路（2-4 步）：

1. 判别函数输出一个实数打分。
2. 打分为零的点组成决策边界。
3. 边界两侧对应不同类别。

何时使用：类别大致线性可分时的基础分类器。

多分类线性判别

$$\hat{c} = \arg \max_k y_k(\mathbf{x}), \quad y_k(\mathbf{x}) = \mathbf{w}_k^\top \mathbf{x} + w_{k0}. \quad (2)$$

变量释义：每个类别都有一个打分函数，取最大得分对应的类别。

推导思路（2-4 步）：

1. 多分类时不再只比较正负，而是比较各类得分大小。
2. 两个类别边界由 $y_i(\mathbf{x}) = y_j(\mathbf{x})$ 给出。
3. 因而多分类线性模型仍对应若干超平面拼接出来的区域划分。

何时使用：softmax 之前的 logits 层、线性多分类基线。

3 5.2 Bayes classifier 与风险最小化

最小错误率分类

$$\hat{c}(\mathbf{x}) = \arg \max_k p(C_k | \mathbf{x}). \quad (3)$$

变量释义： $p(C_k | \mathbf{x})$ 是给定输入后的类别后验概率。

推导思路 (2-4 步)：

1. 在 0-1 损失下，预测错记 1，预测对记 0。
2. 每个动作的条件风险就是预测错误的概率。
3. 因而选择后验概率最大的类别即可使错误率最小。

何时使用：默认分类决策规则与理论最优分类器分析。

代价敏感决策

$$R(\alpha_i | \mathbf{x}) = \sum_{k=1}^K \lambda_{ik} p(C_k | \mathbf{x}), \quad \hat{\alpha} = \arg \min_i R(\alpha_i | \mathbf{x}). \quad (4)$$

变量释义： λ_{ik} 表示真实类别为 C_k 时采取动作 α_i 的代价。

推导思路 (2-4 步)：

1. 实际任务中不同错误的后果通常不一样。
2. 因此不能只看谁的后验概率大，还要看错误代价大小。
3. 最优动作是最小化条件期望风险，而非单纯最大后验类别。

何时使用：医学诊断、欺诈检测、工业告警等高代价不对称场景。

4 5.3 生成式与判别式

两种建模路线

生成式: $p(C_k | \mathbf{x}) \propto p(\mathbf{x} | C_k)p(C_k),$ (5)

判别式: 直接建模 $p(C_k | \mathbf{x})$ 或判别函数 $y_k(\mathbf{x})$. (6)

变量释义: 生成式先描述“各类数据长什么样”，判别式则直接描述“给定输入属于哪一类”。

推导思路 (2-4 步):

1. 生成式模型先建联合分布或类条件分布。
2. 判别式模型直接针对分类边界或后验概率建模。
3. 前者更完整，后者通常更贴近预测目标。

何时使用: 小样本、缺失值处理偏向生成式；纯预测精度常偏向判别式。

5 5.4 Logistic 回归

Sigmoid 概率输出

$$p(C_1 | \mathbf{x}) = \sigma(a), \quad a = \mathbf{w}^\top \mathbf{x} + w_0, \quad (7)$$

$$\sigma(a) = \frac{1}{1 + e^{-a}}. \quad (8)$$

变量释义: a 是 logit, $\sigma(a)$ 把任意实数压缩到 $(0, 1)$ 。

推导思路 (2-4 步):

1. 先用线性函数得到实数打分。
2. 再用 sigmoid 把打分映射为概率。
3. 于是模型输出可解释为二分类后验概率。

何时使用: 二分类任务、概率预测与可解释线性分类。

后验 odds 与 logit 的线性关系

$$\log \frac{p(C_1 | \mathbf{x})}{p(C_2 | \mathbf{x})} = \mathbf{w}^\top \mathbf{x} + w_0. \quad (9)$$

变量释义：左边是 posterior odds 的对数，也叫 logit。

推导思路 (2-4 步)：

1. Logistic 回归直接建模正类后验概率。
2. 把 sigmoid 公式两边取 odds 再取对数，就得到线性形式。
3. 这说明 Logistic 回归实际上是在建模“后验 odds 的对数是输入的线性函数”。

何时使用：解释 Logistic 回归为何既是概率模型又是线性分类器。

Bernoulli 似然与交叉熵

$$p(\mathbf{t} | X, \mathbf{w}) = \prod_{n=1}^N y_n^{t_n} (1 - y_n)^{1-t_n}, \quad (10)$$

$$E(\mathbf{w}) = - \sum_{n=1}^N [t_n \log y_n + (1 - t_n) \log(1 - y_n)]. \quad (11)$$

变量释义： $t_n \in \{0, 1\}$, $y_n = p(C_1 | \mathbf{x}_n)$ 。

推导思路 (2-4 步)：

1. 把每个标签看成 Bernoulli 观测。
2. 独立样本下，总似然是所有 Bernoulli 概率的乘积。
3. 取负对数后得到二分类交叉熵。

何时使用：二分类神经网络输出层和广义线性模型。

Logistic 梯度为什么会化简成 $y - t$

对单个样本，损失为

$$E_n = -t_n \log y_n - (1 - t_n) \log(1 - y_n), \quad y_n = \sigma(a_n).$$

先对 y_n 求导，再乘上 $dy_n/da_n = y_n(1 - y_n)$ ，可得

$$\frac{\partial E_n}{\partial a_n} = y_n - t_n.$$

这个结果非常重要，因为输出层误差正好就是“预测概率减真实标签”。

6 5.5 Softmax 回归

Softmax 概率

$$p(C_k | \mathbf{x}) = \frac{\exp(a_k)}{\sum_{j=1}^K \exp(a_j)}, \quad a_k = \mathbf{w}_k^\top \mathbf{x} + w_{k0}. \quad (12)$$

变量释义： a_k 是第 k 类的 logit。

推导思路 (2-4 步)：

1. 每个类别先产生一个实数打分。
2. 指数化后变成正权重。
3. 再除以总和，得到和为 1 的概率分布。

何时使用：单标签多分类任务的标准输出层。

Categorical 似然与多分类交叉熵

$$p(T | X, \mathbf{W}) = \prod_{n=1}^N \prod_{k=1}^K y_{nk}^{t_{nk}}, \quad (13)$$

$$E(\mathbf{W}) = - \sum_{n=1}^N \sum_{k=1}^K t_{nk} \log y_{nk}. \quad (14)$$

变量释义： t_{nk} 是 one-hot 标签。

推导思路 (2-4 步)：

1. 单个多分类标签服从 categorical 分布。
2. one-hot 标签让真实类别对应的概率项被保留。
3. 取负对数后得到多分类交叉熵目标。

何时使用：多分类网络训练与概率输出解释。

Softmax 输出层梯度

$$\frac{\partial E_n}{\partial a_{nk}} = y_{nk} - t_{nk}. \quad (15)$$

变量释义： a_{nk} 是第 n 个样本对第 k 类的 logit, y_{nk} 是 softmax 概率。

推导思路 (2-4 步)：

1. 先对多分类交叉熵对 y_{nk} 求导。
2. 再结合 softmax 的 Jacobian 做链式法则展开。
3. 最终同样化简成“预测概率减 one-hot 标签”。

何时使用：多分类网络输出层反向传播。

7 总结与常见误区

- 分类应理解为“概率估计 + 决策规则”，而不是只画一条边界。
- Bayes classifier 给出最小错误率决策，代价敏感任务则要最小化期望风险。
- Logistic 和 Softmax 的交叉熵都来自明确的概率似然。
- 误区 1：把最大后验和最小风险混为一谈。
- 误区 2：认为生成式和判别式只能二选一；它们服务的目标不同。
- 误区 3：把 softmax 概率直接当作绝对可信置信度，而不做校准检查。